



华南师范大学  
SOUTH CHINA NORMAL UNIVERSITY

# 本科毕业论文

题 目 : 无源域自适应目标检测

指导老师 : 陆玉武

学生姓名 : 陈炜俊

学 号 : 20222005195

院 系 : 人工智能学院

专 业 : 软件工程

毕业时间 : 2026年7月

# 无源域自适应目标检测

## 摘要

目标检测作为智能感知系统的关键技术，广泛应用于自动驾驶、智慧城市与工业检测等场景，但模型在跨场景部署时常因训练数据与测试数据分布不一致而出现性能下降。传统的领域自适应目标检测通常需要同时访问源域与目标域数据以缩小特征分布差异，然而在实际应用中，源域标注数据往往受到隐私法规、传输成本或数据产权等因素限制而不可获取，这推动了无源域自适应（Source-Free Domain Adaptation, SFDA）设定的研究。现有无源域目标检测方法多采用 Mean Teacher 自训练范式，但在域偏移较大时，教师模型生成的伪标签噪声会导致误差累积，进而引发训练不稳定甚至性能崩溃。为同时提升训练稳定性与目标域特征判别力，本文设计了一种“动态师生协同与实例关系图引导”的无源域自适应目标检测框架：在稳定性方面，引入 PETS 多教师机制，通过静态教师、动态教师与学生模型协同训练，并采用周期性交换与教师共识伪标签生成，以缓解单教师框架中误差积累与训练失稳问题；在表征增强方面，引入 IRG 实例关系图网络建模候选实例间关系，并以图引导对比学习的方式构造更可靠的正负样本对，从而强化目标域实例级特征表示。实验在典型无源域自适应目标检测场景上进行验证，结果表明所提出的融合框架能够在保持训练过程更稳定的同时，获得更优的目标域检测性能。

**关键词：**无源域自适应；目标检测；教师—学生；伪标签；对比学习；实例关系图

# Source-Free Domain Adaptive Object Detection

## ABSTRACT

Object detection is a core capability of intelligent perception systems, yet detectors often suffer from performance degradation when deployed in unseen visual domains due to domain shift. While conventional domain adaptive object detection typically assumes access to both source and target data to reduce distribution discrepancy, real-world deployment may restrict source data availability because of privacy regulations, transmission costs, or proprietary concerns, motivating the Source-Free Domain Adaptation (SFDA) setting. Existing source-free object detection methods commonly adopt a Mean-Teacher self-training paradigm, but noisy pseudo-labels under severe domain shift can accumulate errors and lead to training instability or even collapse. To improve both training stability and target-domain discriminability, this thesis presents a framework that combines dynamic teacher–student collaboration with instance relation graph guidance. For stability, we incorporate the PETS multi-teacher scheme, consisting of a static teacher, a dynamic teacher, and a student, and employ periodic weight exchange and a consensus pseudo-labeling strategy to mitigate error accumulation. For representation enhancement, we introduce an Instance Relation Graph (IRG) network to model object relations and guide a contrastive learning objective, enabling more reliable positive/negative pair construction and stronger target representations. Experiments on a typical SFOD benchmark setting indicate that the proposed combined approach yields more stable adaptation and improved detection performance on the target domain.

Key Words: source-free domain adaptation; object detection; teacher–student; pseudo-labeling; contrastive learning; instance relation graph

## 目 录

# 第一章 绪论

## 1.1 选题背景与意义

### 1.1.1 选题背景

目标检测需要同时完成目标类别识别与位置定位，是自动驾驶、智慧安防与工业质检等智能感知系统的基础能力。随着模型从实验环境走向真实部署，跨场景泛化能力逐渐成为影响落地效果的关键因素。

在实际应用中，训练数据与部署环境往往存在分布差异，导致模型在新环境中出现精度下降，这一现象通常称为域偏移。对于目标检测任务而言，域偏移不仅会削弱类别判别，还会影响边界框回归的稳定性，从而引发漏检、误检或定位偏移等问题。

传统领域自适应目标检测多假设适应阶段仍可访问源域标注数据，通过源域和目标域联合训练缩小差异。然而在隐私合规、数据主权、传输成本与商业机密保护等约束下，源域不可访问在实际部署中更为常见。由此产生无源域自适应目标检测（Source-Free Domain Adaptive Object Detection, SFOD）设定：在不访问源域样本的前提下，仅依赖源模型参数与目标域无标签数据完成跨域适配。

### 1.1.2 选题意义

在工程实践层面，SFOD 能在不共享源数据的条件下进行跨场景适配，降低数据流转与二次标注成本，缩短部署周期，并提升系统在隐私受限场景中的可落地性与可维护性。

在研究层面，SFOD 将适应过程置于无标签和强域偏移的困难条件下，训练监督更多依赖伪标签与自监督信号。如何在噪声监督下保持训练稳定、避免误差累积导致性能退化，并进一步提升目标域特征的判别能力，是该方向的核心问题。

## 1.2 研究现状概述

### 1.2.1 从 DAOD 到 SFOD 的演进

有源域领域自适应目标检测（DAOD）允许适应阶段访问源域标注数据与目标域无标注数据，研究通常围绕两域特征对齐与迁移展开，在公开基准上取得了较好效果。但该设定依赖源数据可访问，与现实中“源数据不可共享”的约束存在冲突。

SFOD 在仅提供源模型参数、且适应阶段仅使用目标域无标签数据的条件下完成迁移，应用约束更贴近真实场景，但也使训练更容易受到目标域噪声信号影响，稳定性与有效性面

临更大挑战。

### 1.2.2 目前 SFOD 的主线方法

现阶段 SFOD 的主流方法多基于教师—学生自训练 Mean Teacher 框架：教师为目标域样本生成伪标签，学生在伪标签监督下更新，教师再由学生参数的指数滑动平均 EMA 进行更新。该框架实现简单、适配性强，因此被大量工作采用与扩展。

围绕该框架的改进主要集中在两条主线：一是提升伪标签可靠性并增强训练稳定性（如更合理的过滤/融合策略、多模型协同与更稳的更新机制等），以缓解强域偏移下伪标签噪声引发的误差累积；二是引入对比学习等自监督信号增强目标域表征质量，但检测任务下正负样本对构造更困难，需结合更结构化的关系信息以降低配对噪声。

总体而言，训练稳定性与目标域判别力不足仍是制约 SFOD 性能提升的主要矛盾，也是本文的切入点。

### 1.3 本文研究内容与技术路线

针对 SFOD 场景下训练不稳定和目标域特征判别力不足两类问题，本文围绕两条主线设计并整合为统一适应框架：

(1) 宏观稳定性：引入周期性交换师生 PETS 思想构建静态教师、动态教师与学生三模型协同训练机制，通过更稳的更新调度与共识伪标签抑制误差累积，降低训练波动与崩溃风险。

(2) 微观判别力：引入实例关系图 IRG 思想，对目标域候选实例间关系进行建模，将关系信息用于构造更可信的正负样本对，引导对比学习优化特征空间，提升实例级表征能力。

适应阶段仅使用目标域无标签数据与源模型参数：一方面通过 PETS 提供更稳定的伪标签监督与训练调度，降低自训练的性能波动；另一方面通过 IRG 提供结构化的自监督信号，增强目标域特征的聚类性与可分性，从而提升最终检测精度。两部分在同一训练流程中协同作用，形成稳定性与判别力的互补增强。

### 1.4 本文主要工作与创新点

本文主要贡献可归纳为以下两个方面，如表1-1所示。

一方面，将 PETS 的稳定训练范式与 IRG 的结构化自监督信号进行结合，构建了“动态师生协同与实例关系图引导”的无源域自适应目标检测框架，使得训练过程同时具备更强

的抗噪能力与更好的特征学习能力。该结合并非简单叠加，而是围绕同一学生模型的优化目标进行统一设计，使伪标签监督与对比学习在同一训练流程中协同发挥作用。

另一方面，本文在训练监督上采用多教师共识伪标签策略，通过静态教师与动态教师的预测一致性提升伪标签质量；在表征增强上采用图引导对比学习，将实例关系显式引入正负样本构造，从而共同优化目标域检测性能，达到更稳与更准的综合效果。

表1-1 方案对应信息表

关键问题	对应方法	预期效果
训练不稳定（单教师误差累积，易崩溃）	PETS：静态教师/动态教师/学生三模型协同；周期性交换；双教师共识伪标签	抑制误差累积与灾难性崩溃；训练过程更稳、伪标签更可靠
判别力不足（目标域特征分离度弱）	IRG：构建实例关系图；图引导生成正负样本对；对比学习损失	强化实例级特征聚类与分离；提升目标域检测精度

## 1.5 论文结构安排

第一章为绪论，介绍研究背景与意义，概述研究现状，并给出本文研究内容与总体技术路线。

第二章介绍目标检测与领域自适应相关基础，包括教师一学生自训练、伪标签与对比学习等关键技术概念，为后续方法阐述提供支撑。

第三章对相关研究工作进行综述与归纳，从有源域 DAOD 到无源域 SFOD 的方法演进进行总结，并分析现有方法的不足与本文切入点。

第四章详细介绍本文提出的融合方法，给出总体框架、关键模块设计与训练流程，并说明各组成部分的协同方式。

第五章从软件工程实现角度描述系统设计与实现，按照模块化思路介绍数据处理、模型构建、伪标签生成、图关系建模与训练调度等功能实现。

第六章给出实验设置与结果分析，通过对比实验与消融实验验证本文方法在稳定性与精度方面的效果，并讨论方法优势与局限。

第七章对全文工作进行总结，并对后续可能的改进方向与扩展应用进行展望。

## 1.6 本章小结

本章阐述了域偏移导致目标检测跨场景性能下降的问题，并说明在隐私合规与数据主权

等约束下，SFOD 设定具有现实必要性。随后概述了 SFOD 的主流研究路线及其在强域偏移下的主要矛盾：训练稳定性不足与目标域判别力有限。最后给出本文以 PETS 提升稳定性、以 IRG 增强判别力并协同实现更稳且更准的总体研究思路。

## 第二章 相关技术基础

### 2.1 目标检测基础

目标检测需要同时解决类别识别与目标定位。两阶段检测器因定位精度较高、训练较稳定，常被用作领域自适应检测的基础框架。Faster R-CNN 的流程可概括为：先生成候选区域，再对候选区域进行分类与边界框回归，如图2-1所示。

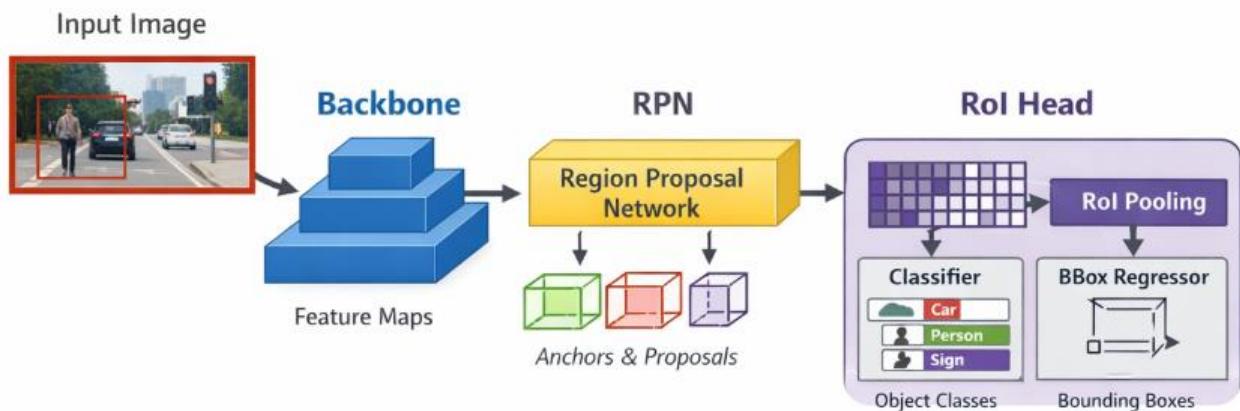


图2-1 Faster R-CNN 流程图

#### 2.1.1 两阶段检测器的基本组成

Faster R-CNN 主要由 Backbone、RPN 与 RoI Head 构成：Backbone 提取特征；RPN 在特征图上生成候选区域并进行初步回归；RoI Head 将候选区域映射到固定尺寸特征后，输出类别与更精细的边界框回归结果。三者分工明确，便于在跨域场景下进行稳定训练与性能分析。

#### 2.1.2 损失函数与训练目标

Faster R-CNN 的训练通常由两类监督信号构成：分类损失与回归损失，并分别作用于 RPN 与 RoI Head。

在 RPN 阶段，分类损失用于区分候选框是否为目标（前景/背景），回归损失用于优化

候选框的位置与尺度，使其更贴近真实目标。进入 RoI Head 后，分类损失进一步细化为多类别分类，回归损失则对目标框做更精确的边界框回归。整体训练目标可以理解为：让网络既能准确找出目标区域，也能稳定地将目标框框得更准。

### 2.1.3 评价指标：mAP 与 AP50

常用指标为 AP 与 mAP。本文采用  $\text{IoU}=0.5$  的评价方式：当预测框与真实框的 IoU 不低于 0.5 视为匹配，由此得到 AP50；对各类别 AP50 取平均得到 mAP@0.5。后文默认在该阈值下报告 AP50 与 mAP（或 mAP@0.5）。

## 2.2 领域自适应与无源域设定

领域自适应旨在尽量不增加标注成本的前提下，将源域知识迁移到目标域并保持性能。UDA 设定下适应阶段可同时访问源域标注数据与目标域无标注数据；SFDA 则进一步要求适应阶段不访问源域样本，仅提供源模型参数与目标域无标签数据。将该约束落到目标检测任务即无源域自适应目标检测（SFOD）。

由于无法回看源域样本，SFOD 的适应过程更依赖伪标签与自监督信号，训练稳定性与表征判别力问题更为突出。

## 2.3 教师—学生与伪标签

在无监督或弱监督条件下，“教师—学生”自训练是一条常用思路。其核心做法是：先由一个相对稳定的模型教师为无标签数据生成伪标签，再用这些伪标签监督另一个可学习的模型学生更新参数。随着训练推进，学生能力提升，教师也随之更新，从而形成“自我增强”的闭环，如图2-2所示。

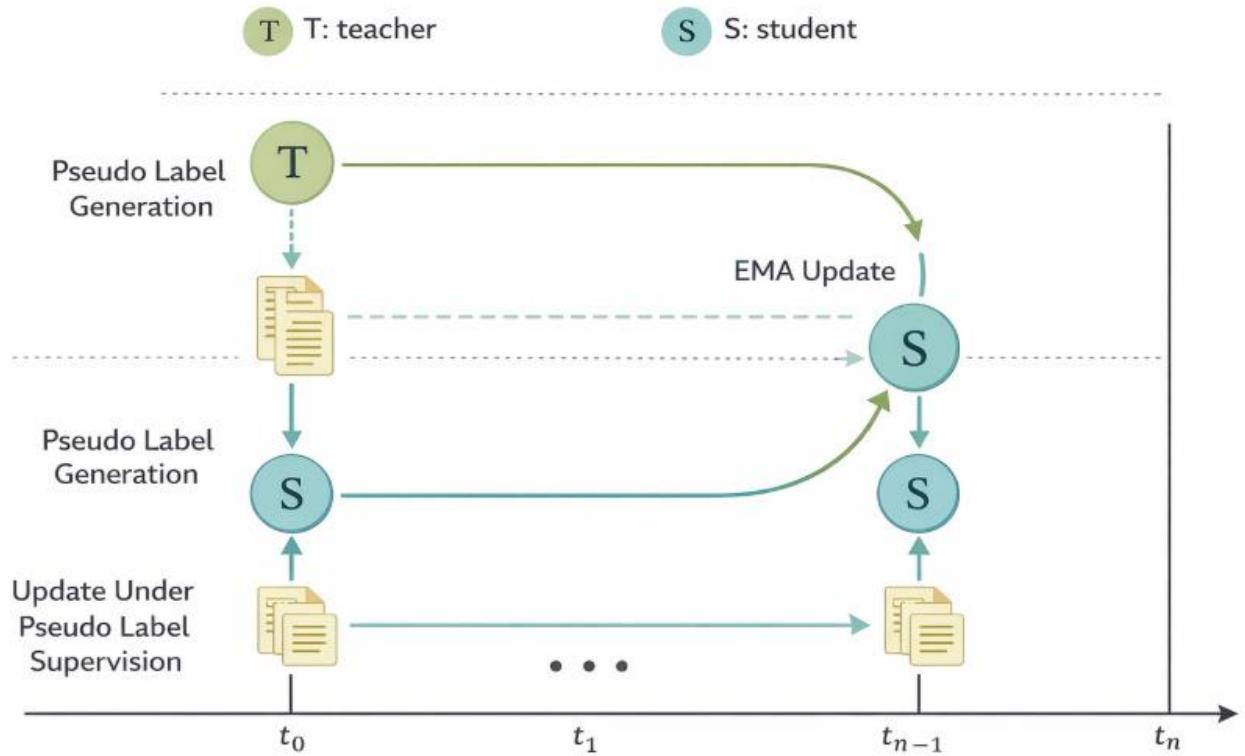


图2-2 教师学生框架的迭代更新流程图

### 2.3.1 EMA 更新与一致性监督

Mean Teacher 通常用指数滑动平均 EMA 更新教师参数，使教师变化更平滑，从而为学生提供更稳定的监督信号。检测任务中常结合“弱增强—强增强”策略：教师在较弱增强视图上生成伪标签，学生在较强增强视图上学习，以提升对扰动的鲁棒性。

### 2.3.2 伪标签阈值过滤与噪声问题

伪标签在强域偏移下不可避免存在噪声。常用做法是置信度阈值过滤：仅保留高置信度预测以降低噪声干扰，但阈值过高会导致有效伪标签不足，过低则会引入大量错误监督。更关键的是误差累积：当教师预测存在偏差时，学生会被错误监督带偏；而教师又由学生 EMA 更新，偏差可能在闭环中被持续固化，导致训练波动甚至性能崩溃。后续章节中，PETS 通过多教师协同、周期性交换与共识伪标签机制缓解该类问题。

## 2.4 对比学习基础

对比学习的核心目标是学习更可分的特征表示，把语义相近的样本拉近，把语义不同的样本推远。相比直接依赖伪标签的监督方式，对比学习更强调从数据本身构造自监督信号，

因此常被用来增强目标域特征的聚类性与判别性。

在经典的对比学习设定中，通常会为同一个样本构造两种不同视图（例如不同增强方式下的同一图像），并将它们视为正样本对；同时将其他样本视为负样本，用于形成拉近一推远的对比关系。通过这种机制，模型可以学到对抗更不敏感、对语义更敏感的表征，如图2-3所示。

对检测任务而言，对比学习面临一个直接难点：一张图像往往包含多个实例，而 RPN 生成的 proposals 又是类别无关的候选区域。在缺少目标域真实标注时，很难解决哪个 proposal 与哪个 proposal 应该视为同一实例的正对，哪些应视为负对的问题。如果正负样本对构造不可靠，对比学习反而可能引入额外噪声。因此，后续章节引入 IRG 的动机之一，就是通过显式的关系建模来更稳健地构造检测场景中的正负样本对。

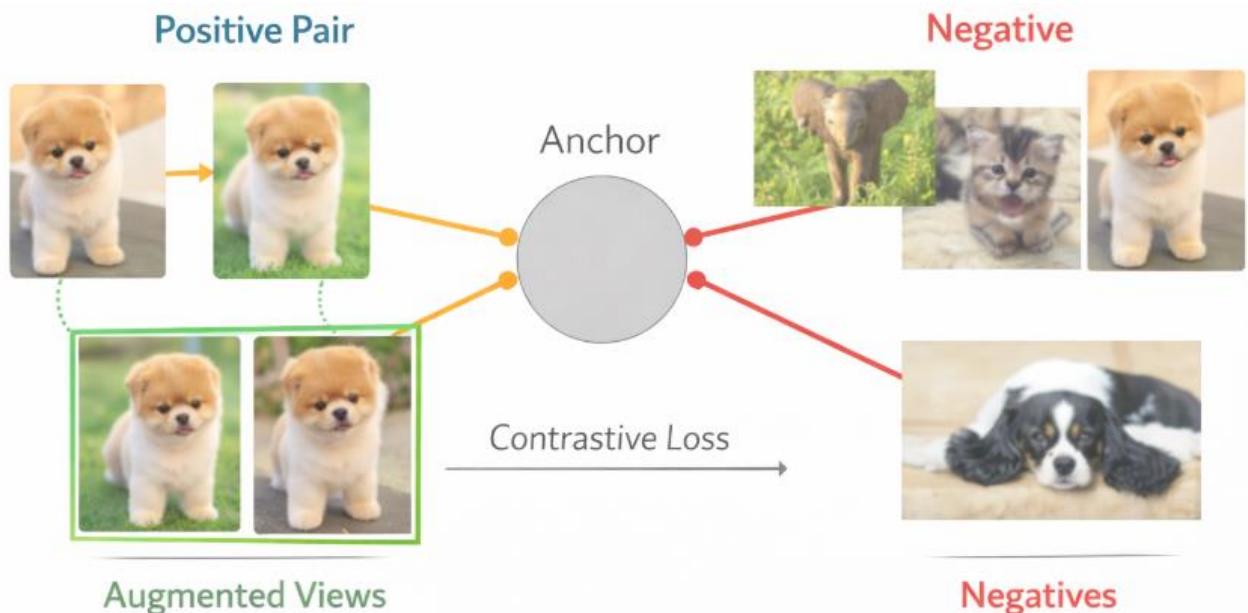


图2-3 对比学习示意图

## 2.5 图神经网络与关系建模

图神经网络适用于处理“元素之间存在关系”的数据结构。与传统卷积主要刻画规则网格，例如图像像素邻域不同，图结构更强调节点之间的连接关系，可用于表达实例之间的相似性、依赖性或上下文关联，如图2-4所示。

## Traditional Convolutional Networks

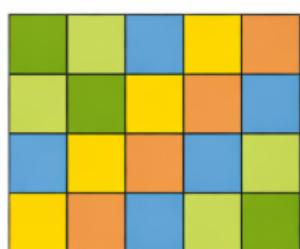
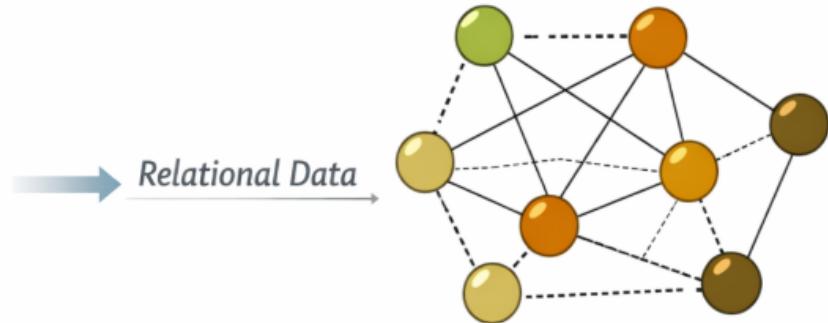


Image Grid

## Graph Neural Networks



Graph Structure

Similarity | Dependency | Context

图2-4 传统卷积与图神经网络示意图

### 2.5.1 节点、边与邻接矩阵

图由节点（Node）与边（Edge）组成。节点可以理解为需要被建模的对象，例如检测任务中每一个候选实例的 RoI 特征；边用于表示节点之间是否相关、相关程度如何，例如两个候选框是否可能属于同一目标、它们在特征空间中的相似度大小等。

邻接矩阵是一种常用表示方式：若图中共有  $m$  个节点，则可用一个  $m \times m$  的矩阵记录任意两节点之间的关系强度。矩阵元素越大，表示两节点越相似或关联越强；越小则表示关联弱。借助邻接矩阵，图结构可以方便地参与后续计算与学习。

GCN（Graph Convolutional Network）可以理解为“在图上做特征聚合”：每个节点会从其邻居节点接收信息并更新自身表示。经过多层传播后，节点特征不仅包含自身信息，也融入了邻域关系，从而获得更结构化的表征。

### 2.5.2 关系建模构造正负对

在目标检测的无标签目标域中，正负样本对难以直接定义，而图关系建模提供了一条可行路径：先把候选实例当作节点，通过图网络学习节点间的相似关系，再基于关系强弱生成“实例对”的伪标签。例如，当某对节点关系分数较高时，可将其视为正对；关系分数较低时视为负对。这样一来，对比学习不再完全依赖人工规则或不稳定的启发式匹配，而是由模型在学习过程中自适应地给出更符合目标域分布的关系划分。本文后续采用的 IRG 思路，正是利用图网络学习关系矩阵，并据此构造更可靠的正负样本对来提升实例级特征判别力。

## 2.6 本章小结

本章简要介绍了以 Faster R-CNN 为代表的两阶段检测器结构、训练目标与常用评价指标，并给出 SFOD 的问题设定。随后说明教师—学生自训练与伪标签噪声导致的误差累积风险，并引出稳定训练机制的必要性。最后概述对比学习与关系建模用于构造正负样本对的基本思路，为后续 PETS 与 IRG 方法设计提供概念基础。有关术语缩略语如表2-1所示。

表2-1 第二章相关术语表

缩略语	英文全称	含义说明
RPN	Region Proposal Network	区域建议网络，生成候选框
RoI	Region of Interest	感兴趣区域/候选区域
IoU	Intersection over Union	交并比，用于衡量框重合度
AP50	Average Precision at IoU=0.5	IoU=0.5 下的平均精度
mAP@0.5	mean AP at IoU=0.5	各类别 AP50 的平均
MT	Mean Teacher	教师—学生自训练框架
EMA	Exponential Moving Average	指数滑动平均，用于更新教师模型
ST	Static Teacher	静态教师（周期内冻结）
DT	Dynamic Teacher	动态教师（迭代内 EMA 更新）
S	Student	学生模型（主要被优化对象）
WBF	Weighted Boxes Fusion	加权框融合，用于融合多教师预测框
GCN	Graph Convolutional Network	图卷积网络，用于关系建模与特征传播
GCL	Graph Contrastive Loss	图引导对比损失，拉近正对/推远负对

## 第三章 研究现状与文献综述

### 3.1 本章概述

本章围绕从有源域到无源域的研究演进，对领域自适应目标检测相关工作进行归纳。总体而言，DAOD 在可访问源域标注数据的前提下，通过对齐与迁移缩小源/目标域差异；SFOD 在源域不可访问的约束下更依赖自训练与自监督信号，但也更容易受到伪标签噪声与特征退化影响。基于此，本章重点综述本文采用的两条思路：PETS 的稳定训练机制与 IRG 的实例关系引导表征增强。

### 3.2 有源域DAOD检测技术

DAOD 通常允许适应阶段同时使用源域有标注与目标域无标注数据，研究多围绕两域分

布差异展开，常见思路包括图像级、实例级、类别级对齐以及对抗学习等。这类方法在标准基准上能有效提升目标域性能，但依赖源域数据可访问，与隐私合规与数据主权等现实约束不完全匹配，因此更多作为 SFOD 的背景对照。

### 3.2.1 CSDA：类别尺度联合特征对齐

在 DAOD 中，CSDA 的切入点是一个较工程直观的现象：目标在不同尺度上的分布并不均匀时，单纯做类别级对齐可能出现多尺度对齐不均问题，即同一类别的小目标与大目标在特征空间中被对齐的程度不一致，从而导致学习偏置与性能下降。为缓解这一问题，CSDA 强调将“类别信息”和“尺度信息”联合建模，使对齐过程能同时考虑同类目标在不同尺度下的差异。

总体来看，CSDA 的优点在于抓住了多尺度目标检测中的关键矛盾，将类别一致与尺度一致同时纳入对齐目标，在多尺度场景下更稳健。局限在于其依然属于有源域设定，且对抗和对齐模块往往需要额外的训练调参与计算开销，难以直接迁移到源域不可访问的 SFOD 环境中。

## 3.3 无源域SFOD主流范式

无源域自适应目标检测 SFOD 在适应阶段仅允许访问源模型参数和目标域无标签数据。在这一约束下，最常见的做法是沿用教师一学生自训练范式：教师模型对目标域图像预测得到候选框与类别分数，并从中筛选出高置信预测作为伪标签；学生模型在伪标签监督下进行检测训练，随后教师模型再由学生参数的指数滑动平均 EMA 进行更新，从而获得更平滑的监督信号。

从检测损失的角度看，SFOD 的学生端通常仍遵循两阶段检测器，以 Faster R-CNN 为例的基本训练目标，即将 RPN 与 RoI Head 的分类与回归损失相加：

$$\mathcal{L}_{det} = \mathcal{L}_{cls}^{RPN} + \mathcal{L}_{reg}^{RPN} + \mathcal{L}_{cls}^{ROI} + \mathcal{L}_{reg}^{ROI} \quad (3-1)$$

这里  $\mathcal{L}_{cls}^{RPN}$  与  $\mathcal{L}_{reg}^{RPN}$  分别对应 RPN 的前景/背景判别与候选框回归； $\mathcal{L}_{cls}^{ROI}$  与  $\mathcal{L}_{reg}^{ROI}$  则对应 RoI Head 的类别分类与边界框精修回归。SFOD 的不同方法主要差异并不在损失的形式，而在于伪标签如何产生、如何筛选和融合、以及教师如何更新相关问题。

在 Mean Teacher 思想下，学生与教师的更新可以用一组直观的迭代式表达：学生用伪标签的监督损失做梯度下降更新，而教师不直接反传梯度，而是对学生参数做 EMA 平滑更

新：

$$\Theta_s \leftarrow \Theta_s + \gamma \frac{\partial \mathcal{L}_{SL}}{\partial \Theta_s}, \Theta_t \leftarrow \alpha \Theta_t + (1 - \alpha) \Theta_s \quad (3-2)$$

其中  $\Theta_s, \Theta_t$  分别表示学生与教师参数， $\gamma$  是学生学习率， $\alpha$  是 EMA 动量。这种更新方式的直观意义是教师不会被某一次迭代的噪声强烈扰动，而会以时间集成的方式跟随学生，从而为伪标签提供相对稳定的来源。

然而，该范式的核心难点在于伪标签噪声与错误累积。当域偏移较大时，教师在目标域预测会出现类别误判、定位偏移和低置信框问题。若这些错误以伪标签形式监督学生，学生会向错误方向更新；而 EMA 又会把学生偏差逐步写回教师，形成“噪声伪标签  $\rightarrow$  带偏学生  $\rightarrow$  EMA 带偏教师  $\rightarrow$  更噪的伪标签”的闭环，严重时会导致训练不稳定甚至崩溃。正因如此，SFOD 的改进方向通常分化为两条主线，一条是提升伪标签可靠性并增强训练稳定性，另一条则是引入更强的表征学习信号以提升判别性。

### 3.4 PETS：周期性交换师生

PETS 面向 SFOD 中单教师易崩溃的问题，对传统 Mean Teacher 框架进行了结构性改造：引入静态教师（ST）、动态教师（DT）与学生（S）三模型协同，并通过周期性交换把历史稳定知识重新注入训练过程，从机制上降低误差累积风险。

#### 3.4.1 三模型协同

在一个训练周期内，静态教师 ST 保持冻结，作为稳定锚点输出相对稳健的预测；学生 S 作为主要优化对象，在伪标签监督下更新；动态教师 DT 则通过 EMA 跟随学生，承担平滑波动、融合近期信息的角色。DT 的 EMA 更新可写为：

$$\Theta_{DT} \leftarrow \alpha \Theta'_{DT} + (1 - \alpha) \Theta_S \quad (3-3)$$

其中  $\Theta'_{DT}$  是上一迭代的动态教师参数， $\Theta_S$  是当前学生参数。这里  $\alpha$  的作用非常关键：当  $\alpha$  较大时，DT 更新更慢，能够更强地抑制由噪声伪标签导致的短期抖动；当  $\alpha$  较小时，DT 追随学生更快，但也更容易被噪声拖拽。PETS 的动机并不是“单纯调大 EMA 解决问题”，而是进一步引入“周期性纠错”的结构来打断误差闭环。

### 3.4.2 周期性交换

PETS 的关键设计是在每个训练周期结束时交换静态教师与学生的权重，用公式可表达为：

$$\Theta_S^{2t+1} \rightarrow \Theta_{ST}^{2t+2}, \Theta_{ST}^{2t+1} \rightarrow \Theta_S^{2t+2} \quad (3-4)$$

这里  $t$  表示周期编号，可理解为若干轮迭代构成的阶段，交换意味着上一周期结束时的学生参数成为下一周期的静态教师，而上一周期的静态教师参数则成为下一周期学生的初始化。其纠错重点在于若学生在某个周期里被噪声伪标签带偏，下一周期开始时会被拉回到一个更稳的权重状态。同时静态教师更新得很慢，只在周期边界更新一次，从而为训练提供稳定下限。这种机制等价于在训练过程中周期性地重置风险，避免错误沿时间轴无限累积。

### 3.4.3 多教师共识伪标签

在伪标签生成上，PETS 不依赖单一教师，而是利用 ST 与 DT 预测做共识。整体过程可概括为：先对两教师输出进行置信度过滤，再在两组预测中匹配类别一致且 IoU 足够高的候选框，最后对匹配框进行融合以得到更可靠的伪标签。

设静态教师与动态教师对弱增强目标域图像的预测分别为  $Y_{ST}$  与  $Y_{DT}$ ，其中每个预测由边界框  $b$ 、置信度  $c$  与类别  $y$  组成。PETS 对满足 IoU 与类别一致条件的框进行融合，并采用加权框融合 WBF 形式：

$$\tilde{b} = \frac{1}{c} (\sum_{i=1}^N c_{ST}^i b_{ST}^i + \sum_{j=1}^M c_{DT}^j b_{DT}^j), \tilde{c} = \frac{\beta}{N} \sum_{i=1}^N c_{ST}^i + \frac{1-\beta}{M} \sum_{j=1}^M c_{DT}^j \quad (3-5)$$

其中  $N, M$  是同一目标在 ST 或 DT 中匹配到的框数， $C$  是权重归一化项，与两侧置信度求和相关， $\beta \in [0,1]$  控制静态教师和动态教师的比重。从含义上看， $\tilde{b}$  是按置信度加权的框位置平均值， $\tilde{c}$  是融合后的置信度。这样做的价值在于当某一教师出现偏差时，另一教师可以提供约束。而融合过程倾向于保留两者一致且高置信的部分，从而降低确认偏差与噪声传播。

基于融合伪标签  $(\tilde{b}, \tilde{y})$ ，学生在强增强图像  $\bar{x}_t$  上进行训练，其损失仍对应 Faster R-CNN 的四项检测损失之和：

$$\mathcal{L}_{s\_det} = \sum_{\bar{x}_t \in \mathcal{X}_T} (\mathcal{L}_{cls}^{RPN}(\Theta_S(\bar{x}_t), \tilde{y}) + \mathcal{L}_{reg}^{RPN}(\Theta_S(\bar{x}_t), \tilde{b}) + \mathcal{L}_{cls}^{ROI}(\Theta_S(\bar{x}_t), \tilde{y}) + \mathcal{L}_{reg}^{ROI}(\Theta_S(\bar{x}_t), \tilde{b})) \quad (3-6)$$

这里弱增强用于教师预测、强增强用于学生学习的搭配能够提升鲁棒性，教师在较干净视图上输出更稳定的伪标签，学生在更困难视图上学习，从而增强模型对扰动的适应能力。综合来看，PETS 的贡献不在于引入复杂的新损失，而在于通过周期性交换和双教师共识把训练稳定性显式强化，从机制上减缓误差累积与崩溃风险。

### 3.4.4 优点与局限

PETS 的主要优点是将稳定性显式写进训练调度：通过周期性交换与双教师共识，抑制误差累积、降低崩溃概率，并在多数场景下带来更平滑的性能提升。其局限也较明确：训练仍依赖伪标签的总体质量，当目标域偏移极大或初始预测极差时，伪标签上限依然受限；同时，PETS 更强调训练过程的平稳，对实例级表征判别力的增强相对有限，仍可能出现训练不崩，但特征分离不够、精度提升有限的情况。

## 3.5 IRG：实例关系图引导对比学习

IRG 的关注点不是让伪标签更干净，而是让目标域实例特征更可分。其核心动机来自检测任务中的一个现实困难：对比学习需要可靠的正负样本对，但在无标注目标域里，RPN 产生的大量提案 proposals 是类别无关的，难以判断哪些 proposal 属于同一实例的不同视图。IRG 通过显式关系建模，给出了更稳健的正负对构造方式。

### 3.5.1 关系建模

IRG 将每个 proposal 的 RoI 特征视为图节点  $v_i$ ，节点间边权表示特征空间中的关联强度。为得到可学习的关系矩阵，IRG 先对节点做两组可学习映射  $f(\cdot)$  与  $g(\cdot)$ ，计算相似性打分：

$$S_{ij} = f(v_i) \cdot g(v_j)^T \quad (3-7)$$

随后将相似性通过归一化得到边权（可理解为对每个节点的邻接权重进行 softmax 归一化），得到关系矩阵  $E = [e_{ij}]$ 。这种设计的直观意义是：相比于用 IoU 或手工规则定义相关性，IRG 让模型在特征空间里学习更符合语义的关联，从而为后续正负对划分提供依据。

在得到关系矩阵  $E$  后，IRG 使用图卷积式的聚合来生成图增强特征：

$$\tilde{F} = \text{ReLU}(EFW) \quad (3-8)$$

其中  $F$  是按 proposal 堆叠的 RoI 特征矩阵,  $W$  是可学习权重,  $EF$  表示按关系矩阵对邻域信息加权聚合。直观上, 这一步使每个 proposal 的表示不仅包含自身外观信息, 还融合了与其相关 proposals 的上下文信息, 从而让相似实例更靠近、无关实例更分离的结构更容易被学习出来。

### 3.5.2 图蒸馏与图引导对比损失

为了让关系矩阵  $E$  更可靠, IRG 引入图蒸馏损失 (Graph Distillation Loss, GDL), 用分类 logits 的一致性来约束原始特征分支和图增强特征分支, 并同时保持师生输出的一致性:

$$\mathcal{L}_{GDL} = KL(\sigma(Z_{st}), \sigma(\tilde{Z}_{st})) + KL(\sigma(Z_{te}), \sigma(\tilde{Z}_{te})) + KL(\sigma(Z_{st}), \sigma(Z_{te})) \quad (3-9)$$

这里  $Z_{st}, Z_{te}$  分别表示学生与教师在原始 RoI 特征上的分类 logits,  $\tilde{Z}_{st}, \tilde{Z}_{te}$  表示在图增强特征上的分类 logits,  $\sigma(\cdot)$  为 softmax,  $KL(\cdot, \cdot)$  为 KL 散度。三项的含义可以理解为: 前两项保证增加了图增强后, 预测结果不应该改变, 从而迫使 IRG 学到与检测语义一致的关系; 第三项维持师生一致性, 使无标注下的训练更稳定。

在此基础上, IRG 用关系矩阵产生对比学习所需的正负样本对。对任意两个提案 proposals, 若边权超过阈值  $\varepsilon$  则视为正对, 否则为负对:

$$M_{ij} = \begin{cases} 0, & e_{ij} < \varepsilon \\ 1, & e_{ij} \geq \varepsilon \end{cases} \quad (3-10)$$

其中  $M_{ij}$  是实例对标签矩阵。与用伪标签类别硬分正负不同, 这里用学习出来的关系强度决定正负对, 能更好适配检测中 proposal 多、视图多、边界易抖动的特点。

为了计算对比损失, IRG 将 RoI 特征投影为 query 与 key, 并计算实例两两相似 logits:

$$k_i = W_k v_i, q_i = W_q v_i, R_{ij} = q_i(k_j)^T \quad (3-11)$$

随后以每个 proposal  $i$  为 anchor 锚点, 定义正样本集合  $P(i)$  即与  $i$  关系强、 $M_{ij} = 1$  的 proposals 与全集合  $A(i)$  (除自身外的所有 proposals), 给出图引导对比损失 (GCL) :

$$\mathcal{L}_{GCL} = \sum_{i \in I} -\log \left( \frac{\frac{1}{|P(i)|} \sum_{p \in P(i)} \exp(q_i(k_p)^T)}{\sum_{a \in A(i)} \exp(q_i(k_a)^T)} \right) \quad (3-12)$$

从作用机理看, 分子项鼓励 anchor 与关系强的 proposals 表示接近, 分母项则要求其与其他 proposals 保持区分。由于正负对来自关系矩阵而非人工规则, IRG 在无标注目标域里能够更

稳定地构造对比监督，从而增强实例级特征的聚类性与可分性。

最后，IRG 将自训练的伪标签损失与图蒸馏、图对比三者联合，形成整体目标：

$$\mathcal{L}_{SFDA} = \mathcal{L}_{SL}^{st} + \mathcal{L}_{GDL} + \mathcal{L}_{GCL} \quad (3-13)$$

因此，IRG 的优势可以概括为用关系建模解决检测任务中对比学习正负对难定义的问题，并通过蒸馏约束让关系学习更稳定，使最终表征更准。其代价则主要是图构建与图传播带来的额外计算，以及阈值  $\varepsilon$  等超参数对配对质量的影响。

### 3.5.3 优点与局限

IRG 的优势在于把正负对构造从启发式规则转为可学习的关系建模，更适配检测任务的多实例场景；同时对比学习信号与检测结构天然耦合，有助于提升目标域表征的判别性。其局限主要体现在两点：一是图构建与图卷积带来额外计算开销，训练成本上升；二是正负对划分通常依赖阈值等超参数，阈值设置不当可能引入噪声配对，影响对比学习效果。

## 3.6 本章小结

综上，现有 SFOD 方法虽大多基于教师一学生自训练，但仍面临两类核心矛盾。

第一类矛盾是训练稳定性。单教师框架下伪标签噪声易被 EMA 机制累积放大，导致训练过程出现明显波动，严重时甚至崩溃。PETS 通过引入静态教师与周期性交换机制，为训练提供稳定锚点与性能下限，并以双教师共识伪标签缓解确认偏差，使自训练过程更稳定。

第二类矛盾是特征判别力。即便训练过程不崩溃，源域模型在目标域上的实例级表征仍可能不够紧凑与可分，限制最终精度提升。IRG 从关系建模出发，在检测结构中显式学习 proposals 之间的相似关系，并以图引导对比学习构造更可靠的正负样本对，从而强化目标域特征聚类与分离能力，使表征更精准。

因此，本文的切入点是将两者进行融合与协同，用 PETS 解决宏观层面的训练稳定性，用 IRG 提供微观层面的判别性增强，使框架在稳和准两个维度形成互补，如图3-1所示。

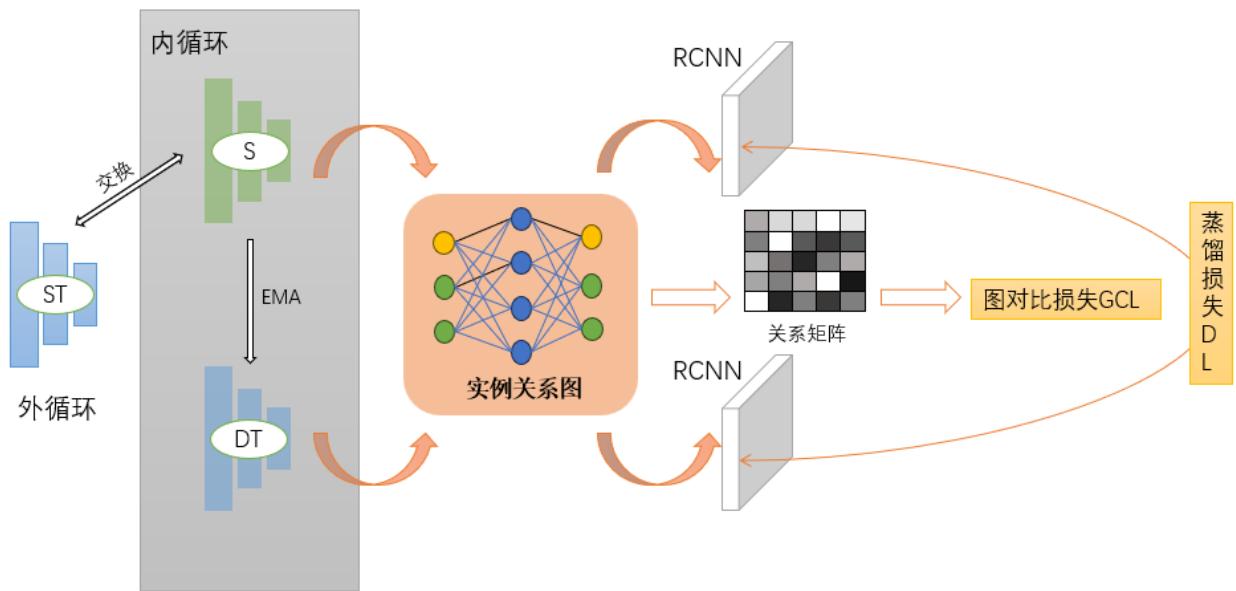


图3-1 PETS与IRG结合框架示意图

新开